

Trabajo Práctico 1 - Aprendizaje Automático

Estudiante: Diego Rojas

Tema: Determinantes de la deserción universitaria y predicción

Resumen

Este trabajo tiene tres objetivos relacionados con la deserción universitaria al cierre del primer año: comprender cómo se distingue la categoría «En curso» mediante una clasificación multiclase; desarrollar un modelo binario que, con información académica y personal del primer año, posteriormente sea utilizado para estimar el riesgo de abandono de estudiantes que continúan en curso en cohortes futuras y oriente acciones de las áreas responsables; y analizar los factores asociados a la deserción mediante una regresión logística explicativa. Con datos de 50.000 estudiantes, Gradient Boosting obtuvo un F1-macro de 0.783 en la tarea multiclase y de 0.940 en la tarea binaria. En el modelo logístico con variables seleccionadas también se obtuvo un F1-macro (0.93) similar al caso de todas las variables, donde el índice de rendimiento académico y la morosidad fueron los predictores con mayor de acuerdo a la importancia de atributos por permutación.

Introducción

Este trabajo aborda la deserción universitaria al finalizar el primer año con tres objetivos complementarios. Primero, comprender la categoría «En curso» y sus diferencias con «Graduado» y «Desertor» mediante una clasificación multiclase. Segundo, construir un modelo binario que estime la probabilidad de abandono para que las áreas responsables puedan utilizarlo como insumo al planificar acciones de acompañamiento para los estudiantes que finalizan el primer año. Tercero, analizar mediante regresión logística qué factores se asocian con la deserción, con el propósito de facilitar la interpretación de sus determinantes. La intención de este estudio, no es sólo ayudar a detectar aquellos estudiantes con riesgo de abandono, sino también ofrecer otras herramientas que ayuden a comprender en detalle cada caso del estudiante detectado.

La literatura teórica (Tinto, 1975, 1993; Bean, 1980; Bean y Metzner, 1985) y empírica (Yorke y Longden, 2004; OECD, 2019) caracteriza la deserción como un fenómeno multicausal, relacionado con factores individuales, institucionales, socioeconómicos y de integración académica. Como la relevancia de estos factores puede variar según el contexto, este estudio evalúa cuáles resultan más informativos en el conjunto de datos analizado.

La pregunta que guía el estudio es **¿cómo permiten las variables disponibles al finalizar el primer año comprender la categoría «En curso», estimar el riesgo de deserción y analizar los factores asociados con el abandono?** Se plantea que el desempeño académico, la situación financiera, la edad y algunas características de ingreso aportan información para esos propósitos. Para abordarlos, se comparan clasificadores multiclase y binarios y se ajusta un modelo logístico con un conjunto reducido de predictores. La tarea binaria se entrena con estudiantes cuyo desenlace se conoce (graduados o desertores) y se propone aplicar el modelo a estudiantes que continúan «En curso» en cohortes futuras, utilizando sus variables observadas durante el primer año. El informe presenta los datos y métodos, los resultados de cada objetivo y sus implicancias y limitaciones.

Materiales y métodos

Se utilizó el conjunto de datos universitario provisto para el trabajo práctico, con 50.000 registros y 27 variables originales. Los nombres de las variables se normalizaron con el formato *lower_snake_case*. Las variables categóricas con respuestas «Sí» y «No» se recodificaron como indicadores binarios (1 y 0). Además, se construyeron variables numéricas derivadas, como promedios de los dos primeros semestres y razones entre variables existentes. El diccionario de datos, que describe las variables y sus valores, puede consultarse [aquí](#). El código, las notebooks de análisis y entrenamiento, los modelos y otros resultados generados están disponibles en el [repositorio del proyecto](#).

Para este estudio se asume que las variables explicativas corresponden a información recopilada al finalizar el primer año y disponible en ese momento para realizar la predicción, mientras que la variable objetivo representa el desenlace académico posterior. Bajo este supuesto, no habría *data leakage* temporal porque los predictores estarían disponibles antes del desenlace que se busca anticipar.

i) Datos y variables explicativas (E)

No se detectaron valores faltantes en las variables analizadas, y las variables numéricas de edad, puntajes y unidades curriculares no presentan valores negativos. La Tabla 1 resume los estadísticos descriptivos de las principales variables numéricas, mientras que la Tabla 2 informa el número de categorías y la moda de las variables categóricas seleccionadas. Se observa que, en algunos registros, la cantidad de unidades curriculares aprobadas supera la cantidad de unidades inscritas. Esto explica que **ratio_aprobadas_inscritas** alcance valores superiores a 1; su máximo es 1,80 (Tabla 1).

Tabla 1. Resumen descriptivo de las variables numéricas del conjunto de datos ($N = 50.000$)

Variable	N	Faltantes	Ceros	Positivos	Negativos	Mín.	Máx.	Media	$p_{0.50}$	DE	CV
cualificacion_promedio	50.000	0	0	50.000	0	48,00	95,00	66,26	67,00	5,52	0,08
puntaje_ingreso	50.000	0	0	50.000	0	48,00	95,00	62,67	62,00	6,28	0,10
edad_inscripcion	50.000	0	0	50.000	0	17,00	70,00	22,28	19,00	6,90	0,31
es_masculino	50.000	0	34.240	15.760	0	0,00	1,00	0,32	0,00	0,46	1,47
es_desplazado	50.000	0	21.452	28.548	0	0,00	1,00	0,57	1,00	0,49	0,87
es_asistencia_diurna	50.000	0	4.244	45.756	0	0,00	1,00	0,92	1,00	0,28	0,30
es_deudor	50.000	0	46.424	3.576	0	0,00	1,00	0,07	0,00	0,26	3,60
es_moroso	50.000	0	5.361	44.639	0	0,00	1,00	0,89	1,00	0,31	0,35
es_becado	50.000	0	37.622	12.378	0	0,00	1,00	0,25	0,00	0,43	1,74
es_estudiante_internacional	50.000	0	49.671	329	0	0,00	1,00	0,01	0,00	0,08	12,29

Variable	<i>N</i>	Faltantes	Ceros	Positivos	Negativos	Mín.	Máx.	Media	<i>p</i> _{0.50}	DE	CV
tiene_necesidades_educativas_especiales	50.000	0	49.808	192	0	0,00	1,00	0,00	0,00	0,06	16,11
promedio_notas_semestres	50.000	0	10.124	39.876	0	0,00	91,00	49,12	60,50	26,22	0,53
promedio_uc_inscritos_semestres	50.000	0	1.744	48.256	0	0,00	21,00	5,92	6,00	1,64	0,28
promedio_uc_aprobadas_semestres	50.000	0	10.127	39.873	0	0,00	20,00	4,10	5,00	2,68	0,65
promedio_cant_evaluaciones_semestres	50.000	0	5.065	44.935	0	0,00	33,00	7,32	7,50	3,32	0,45
ratio_aprobadas_inscritas	50.000	0	10.131	39.869	0	0,00	1,80	0,65	0,83	0,39	0,60
ingresos_familia_nivel	50.000	0	0	50.000	0	1,00	5,00	2,24	2,00	1,12	0,50
demanda_cog_familia_nivel	50.000	0	0	50.000	0	1,00	5,00	2,24	2,00	1,12	0,50

Estadísticos descriptivos de las variables numéricas y frecuencias de valores faltantes y ceros. \$N\$ = número de registros; Positivos/Negativos = valores mayores/menores que cero; \$p_{(0.50)}\$ = mediana; DE = desviación estándar; CV = coeficiente de variación (DE / media); uc = unidades curriculares. En las variables binarias, los ceros y positivos indican las frecuencias de las categorías 0 y 1, respectivamente.

Tabla 2. Resumen descriptivo de las variables categóricas del modelo (*N* = 50.000)

Variable	Faltantes	Niveles	Moda	Frecuencia de la moda	Registros
Estudios_máximos_antes_de_la_inscripción	0	5	Educación Secundaria	43.950	50.000
estado_civil	0	6	Soltero	45.861	50.000
modo_aplicacion	0	4	Acceso General	34.694	50.000
macro_categoria_carrera	0	6	Comunicación, marketing y diseño	12.490	50.000

Propiedades de las variables categóricas. Niveles = cantidad de categorías distintas; Moda = categoría más frecuente; Frecuencia de la moda = número de registros en esa categoría; Registros = total de observaciones analizadas.

ii) Variable respuesta y tarea objetivo (T)

La variable objetivo **target** identifica tres estados académicos: **Graduado**, **Desertor** y **En curso**. Para la clasificación multiclase se conservaron los tres estados y se codificaron como 0, 1 y 2, respectivamente. En la tarea binaria se utilizaron únicamente los casos con desenlace conocido —graduados (0) y desertores (1)—; se excluyeron los estudiantes en curso. El propósito es aplicar el modelo a estudiantes que continúan en curso en cohortes futuras, utilizando sus datos del primer año para estimar el riesgo de abandono.

Como muestra la Tabla 3, los graduados representan el 47,41 % del conjunto, los desertores el 33,06 % y los estudiantes en curso el 19,53 %. Dado que las clases no tienen la misma frecuencia, se estratificaron las particiones y se utilizó F1-macro como métrica de precisión en todos los modelos, ya que otorga el mismo peso a cada clase.

Tabla 3. Distribución de frecuencias de la variable objetivo (target) (*N* = 50.000)

Variable	Frecuencia	Frecuencia relativa (%)
Graduado	23.707	47,41 %
Desertor	16.529	33,06 %
En Curso	9.764	19,53 %

Distribución de categorías de la variable dependiente u objetivo (target) del estudio. Variable = Estado académico final del estudiante; Frecuencia = Número absoluto de estudiantes en cada categoría; Frecuencia relativa (%) = Porcentaje respecto al total de la muestra analizada (\$N\$ = 50.000\$).

iii) Manejo de datos y esquemas de clasificación

Análisis exploratorio de los datos

El análisis exploratorio se realizó antes del ajuste de los modelos. La Figura 1 presenta el agrupamiento jerárquico y la matriz de correlación de Spearman de las variables numéricas. Se observan asociaciones altas entre las unidades curriculares inscritas y aprobadas y las notas de ambos semestres; en varios pares, los coeficientes se sitúan aproximadamente entre 0.8 y 0.9. También se observa una correlación negativa cercana a -0.5 entre los indicadores de deuda y morosidad. Estas relaciones sugieren redundancia entre algunos predictores. Por este motivo, vamos a ver que cuando entrenemos el modelo logístico explicativo (variables seleccionadas) se redujo el conjunto de variables académicas y se construyó un índice compuesto para evitar problemas de multicolinealidad entre las variables.




Figura 1. Agrupamiento jerárquico y matriz de correlación de Spearman de las variables numéricas. Los valores de la matriz representan correlaciones por rangos; el agrupamiento muestra qué variables presentan patrones de asociación similares.

La Figura 2 compara las distribuciones de seis variables numéricas según el estado académico. El promedio de notas y la razón de unidades aprobadas sobre inscritas muestran diferencias más marcadas entre desertores y graduados. En cambio, algunas distribuciones de graduados y estudiantes en curso se superponen, aunque esto no implica que ambos estados sean equivalentes. Esta superposición ayuda a contextualizar la dificultad del modelo multiclasa para identificar correctamente la categoría en curso, como se verá en la Tabla 6.




Figura 2. Distribución de variables numéricas según la categoría de *target*. Las líneas centrales representan las medianas, las cajas el rango intercuartílico y los puntos las observaciones atípicas.

La Tabla 4 presenta las diez variables con los valores más altos de Valor de Información (IV), una métrica que resume cuánto contribuye cada predictor a separar las categorías de una variable objetivo. Se utilizó la formulación habitual del IV para una respuesta binaria; por ello, el cálculo compara **Graduado** con **Desertor** y excluye los casos **En curso**. El ranking se calculó sobre el conjunto binario completo antes de la partición en entrenamiento y prueba y se utilizó únicamente como análisis exploratorio para identificar qué variables podían tener mayor capacidad predictiva.

Como referencia, suelen interpretarse valores de IV inferiores a 0,02 como casi nulos; entre 0,02 y 0,10 como débiles; entre 0,10 y 0,30 como moderados; y entre 0,30 y 0,50 como fuertes. Los valores superiores a 0,50 son inusualmente altos y pueden indicar *data leakage*, por lo que deben revisarse. En el top 10, **ratio_aprobadas_inscritas** (5,38) y **promedio_notas_semestres** (4,33) muestran los valores más altos, seguidos por el promedio de evaluaciones (1,65), la morosidad (1,42) y la condición de becario (0,97). En conjunto, el ranking destaca variables de rendimiento académico y de situación financiera. Vamos a ver más adelante que esto esta bastante en línea con los hallazgos encontrados usando la técnica de importancia de atributos por permutación.

Tabla 4. Top 10 de variables predictoras con mayor Valor de Información (IV)

Variable	Tipo	IV
ratio_aprobadas_inscritas	Numérica	5,38
promedio_notas_semestres	Numérica	4,33
promedio_cant_evaluaciones_semestres	Numérica	1,65
es_moroso	Categórica	1,42
es_becado	Categórica	0,97
edad_inscripcion	Numérica	0,89
carrera	Categórica	0,85
modo_aplicacion	Categórica	0,63
sexo	Categórica	0,57
tiene_deuda	Categórica	0,34

Valor de Información (IV) por variable candidata para distinguir graduados de desertores. El IV no es un porcentaje; depende del modo en que se agrupan los valores de cada predictor.

Partición del conjunto de datos

Para cada tarea, los datos se dividieron en conjuntos de entrenamiento y prueba en una proporción de 80/20, con **random_state=42** y estratificación según la variable objetivo. Los hiperparámetros se seleccionaron mediante validación cruzada estratificada de cinco splits aplicada al conjunto de entrenamiento. El preprocesamiento categórico se incluyó en los *pipelines* para evitar fuga de información entre splits. Los modelos se compararon mediante F1-macro: se calcula el F1-score de cada clase —la media armónica entre *precision* y *recall*— y luego se promedian los resultados con el mismo peso. Esta medida es pertinente ante la distribución desigual de las categorías. Para mostrar los errores por clase se presenta también la matriz de confusión multiclase. Los valores de F1-macro de las Tablas 5 y 7 corresponden al conjunto de prueba.

Las variables categóricas se codificaron mediante *one-hot encoding*. Las variables numéricas se conservaron en sus escalas originales, excepto en K-NN, donde se escalaron previamente porque este algoritmo es sensible a la escala de las variables.

Resultados

Clasificación multiclase

La Tabla 5 resume los modelos multiclase, sus estrategias y los hiperparámetros seleccionados. En regresión logística se evaluaron los esquemas *one-vs-rest* (OvR) y *one-vs-one* (OvO); SVM utilizó OvO, mientras que los demás clasificadores admitieron directamente las tres clases. Gradient Boosting obtuvo el F1-macro más alto (0,7828), seguido por Random Forest (0,7768) y SVM (0,7734). La diferencia entre el primer y el tercer modelo es pequeña y debe interpretarse considerando que se evaluó una única partición de prueba.

Tabla 5. Resultados del ajuste de hiperparámetros y evaluación de modelos de clasificación

Modelo	Estrategia multiclase	Hiperparámetros y rangos evaluados	Valores finales	F1-macro
Regresión Logística (One-vs-Rest)	One-vs-Rest (OvR)	penalty : ["l1", "l2", "elasticnet"] C : [0.001, 0.01, 0.1, 1, 10, 100] l1_ratio : [0.1, 0.5, 0.9] (<i>para elasticnet</i>)	penalty : 'elasticnet' C : 1 l1_ratio : 0.9	0,7613
Regresión Logística (One-vs-One)	One-vs-One (OvO)	penalty : ["l1", "l2", "elasticnet"] C : [0.001, 0.01, 0.1, 1, 10, 100] l1_ratio : [0.1, 0.5, 0.9] (<i>para elasticnet</i>)	penalty : 'l1' C : 10	0,7725
SVM (SVC)	One-vs-One (OvO nativo)	C : [0.1, 1, 10, 100]	C : 100	0,7734
K-NN	Directa (Multiclase nativa)	n_neighbors : [3, 5, 7, 9, 11, 13, 15]	n_neighbors : 15	0,7318
Bagging / Random Forest	Directa (Multiclase nativa)	n_estimators : [100, 200, 400] max_depth : [None, 5, 10, 20] min_samples_split : [2, 5, 10] min_samples_leaf : [1, 2, 4] max_features : ["sqrt", "log2"]	n_estimators : 200 max_depth : 20 min_samples_split : 10 min_samples_leaf : 1 max_features : 'sqrt'	0,7768
Árbol de decisión	Directa (Multiclase nativa)	criterion : ["gini", "entropy"] max_depth : [None, 3, 5, 10, 20] min_samples_split : [2, 5, 10] min_samples_leaf : [1, 2, 4]	criterion : 'gini' max_depth : 5 min_samples_leaf : 4 min_samples_split : 2	0,7690

Modelo	Estrategia multiclase	Hiperparámetros y rangos evaluados	Valores finales	F1-macro
Boosting (Gradient Boosting)	Directa (Multiclase nativa)	n_estimators: [100, 200] learning_rate: [0.01, 0.1, 0.2] max_depth: [2, 3, 5] subsample: [0.8, 1.0]	n_estimators: 100 learning_rate: 0.1 max_depth: 5 subsample: 0.8	0,7828

Hiperparámetros seleccionados mediante búsqueda en rejilla (GridSearchCV) y validación cruzada estratificada de cinco pliegues; F1-macro calculado en el conjunto de prueba y redondeado a cuatro decimales. SVM = máquina de soporte vectorial; K-NN = vecinos más cercanos; OvR = uno contra el resto; OvO = uno contra uno.

La Tabla 6 presenta la matriz de confusión del mejor modelo multiclase en el dataset de prueba: las filas corresponden a las clases reales y las columnas, a las predichas. La codificación es 0 = graduado, 1 = desertor y 2 = en curso. El modelo clasificó correctamente el 91,9 % de los graduados (4.356 de 4.741), el 81,6 % de los desertores (2.698 de 3.306) y el 59,5 % de los estudiantes en curso (1.163 de 1.953). Además, asignó a la clase graduado el 28,8 % de los casos que estaban en curso. Esto muestra que «En curso» es la clase más difícil de identificar, pero tampoco, esto justifica combinarla con graduados, ya que representan estados académicos diferentes. A lo sumo se pudiera usar para estimar la probabilidad de abandono luego de entrenar el modelo binario que vamos a ver más adelante.

Este patrón es coherente con los diagramas de caja de la Figura 2, donde varias variables numéricas presentan distribuciones similares para «En curso» y «Graduado». Esa superposición puede contribuir a que el modelo confunda ambas clases, aunque no explica por sí sola todos los errores de clasificación.

Tabla 6. Matriz de confusión del mejor modelo seleccionado (Gradient Boosting) en conjunto de prueba

	Predicho: Clase 0	Predicho: Clase 1	Predicho: Clase 2	Total Real
Real: Clase 0	4.356	62	323	4.741
Real: Clase 1	241	2.698	367	3.306
Real: Clase 2	562	228	1.163	1.953
Total Predicho	5.159	2.988	1.853	10.000

Matriz de confusión de Gradient Boosting en el conjunto de prueba (\$N = 10.000\$). Filas = clase real; columnas = clase predicha; la diagonal contiene los aciertos y las restantes celdas, los errores.

Clasificación binaria

La tarea binaria incluyó 40.236 registros con desenlace conocido: graduados y desertores. La Tabla 7 presenta los F1-macro obtenidos en el conjunto de prueba. Gradient Boosting alcanzó el valor más alto (0,9404), seguido por SVM (0,9403), regresión logística (0,9383) y Voting (soft) (0,9394); K-NN obtuvo 0,9142. La diferencia entre Gradient Boosting y SVM es mínima, y el ensamble no superó a los modelos individuales.

Tabla 7. Resumen de optimización de hiperparámetros y F1-macro por modelo de clasificación

Modelo	Hiperparámetros y rangos evaluados	Valores finales	F1-macro
Regresión logística	penalty: ["l1", "l2", "elasticnet"] C: [0.001, 0.01, 0.1, 1, 10, 100] l1_ratio: [0.1, 0.5, 0.9] (para elasticnet)	penalty: 'l1' C: 1	0,9383
SVM	C: [0.1, 1, 10, 100]	C: 100	0,9403
K-NN	n_neighbors: [3, 5, 7, 9, 11, 13, 15]	n_neighbors: 13	0,9142
Random Forest	n_estimators: [100, 200, 400] max_depth: [None, 5, 10, 20] min_samples_split: [2, 5, 10] min_samples_leaf: [1, 2, 4] max_features: ["sqrt", "log2"]	n_estimators: 400 max_depth: 20 min_samples_split: 5 min_samples_leaf: 1 max_features: 'sqrt'	0,9381
Árbol de decisión	max_depth: [None, 3, 5, 10, 20] min_samples_split: [2, 5, 10] min_samples_leaf: [1, 2, 4] criterion: ["gini", "entropy"]	max_depth: 5 min_samples_leaf: 2 min_samples_split: 2 criterion: 'gini'	0,9338
Gradient Boosting	n_estimators: [100, 200] learning_rate: [0.01, 0.1, 0.2] max_depth: [2, 3, 5] subsample: [0.8, 1.0]	n_estimators: 200 learning_rate: 0.1 max_depth: 3 subsample: 0.8	0,9404
Voting (soft)	Combinación de regresión logística, SVM y Random Forest	voting: 'soft'	0,9394

Hiperparámetros seleccionados mediante GridSearchCV con validación cruzada estratificada de cinco pliegues; F1-macro calculado en el conjunto de prueba y redondeado a cuatro decimales. Voting (soft) combina las probabilidades de regresión logística, SVM y Random Forest; SVM = máquina de soporte vectorial; K-NN = vecinos más cercanos.

Dado el desempeño previo, podemos emplear el modelo de Gradient Boosting para las predicciones y complementar con una regresión logística para comprender mejor los factores clave detrás de la deserción estudiantil.

Para facilitar la interpretación, ajustamos la regresión logística con un conjunto acotado de predictores donde simplificamos algunas variables académicas. En particular, estandarizamos el promedio de notas y la tasa de aprobación (unidades aprobadas/inscritas) según la media y desviación estándar del entrenamiento, y las sintetizamos en una única variable: `indice_rendimiento_academico`. Como muestra la Figura 3, las correlaciones del modelo final son moderadas, corrigiendo el solapamiento observado entre las variables académicas originales (Figura 1).




Figura 3. Agrupamiento jerárquico y matriz de correlación de Spearman de las variables seleccionadas. El índice de rendimiento combina las variables académicas estandarizadas.

Modelo logístico explicativo

La regresión logística se estimó con un conjunto reducido de predictores para facilitar la interpretación. A continuación, se examinan primero la curva de complejidad para diferentes valores del hiperparámetro C , después se realiza lo mismo pero analizando los coeficientes de las variables del modelo, y por último, la importancia de las variables usando permutación.

Curva de complejidad

La Figura 4 muestra la curva de complejidad de la regresión logística con regularización L1. El eje horizontal representa el hiperparámetro C , inverso de la fuerza de regularización: cuanto menor es C , mayor es la penalización. El F1-macro de entrenamiento y prueba aumenta con rapidez para los valores más bajos de C y se estabiliza alrededor de 0,1 donde ambas curvas se mantienen próximas en ese tramo. La búsqueda por validación cruzada de la regresión logística comparativa (Tabla 7) seleccionó $C = 1$, pero en este caso vemos que un valor más bajo de C ya estabiliza los errores.

Curva de complejidad - Regularización Lasso (L1)




Figura 4. F1-macro en entrenamiento y prueba para distintos valores de C . Un valor menor de C implica una regularización más intensa.

Coefficientes del modelo Lasso

La Tabla 8 presenta los coeficientes de la regresión logística ajustada sobre las variables seleccionadas mediante regularización Lasso (L1, con $C = 0,1$). Dado que la deserción se codificó como 1, los coeficientes positivos indican un incremento en las *log-odds* (y por tanto en la probabilidad) de desertar, mientras que los coeficientes negativos se asocian con una menor probabilidad de deserción, manteniendo constantes los demás predictores.

Entre las variables cuantitativas estandarizadas, el `indice_rendimiento_academico` es la variable que más disminuye la probabilidad de abandonar los estudios ($\beta = -3,330$), mientras que la condición de morosidad constituye el factor que más incrementa dicho riesgo ($\beta = 3,469$). También aumentan la probabilidad de deserción la pertenencia a la carrera de *Ingeniería y tecnología* ($\beta = 1,383$), la presencia de necesidades educativas especiales ($\beta = 0,812$), el género masculino ($\beta = 0,513$) y el promedio de evaluaciones semestrales ($\beta = 0,247$). Por el contrario, contar con una beca ($\beta = -1,353$), cursar carreras del área de la *Salud* ($\beta = -0,892$) o ser estudiante internacional ($\beta = -0,815$) reducen significativamente el riesgo de desertar.

Las variables categóricas se interpretan respecto a sus categorías de referencia omitidas. La gran mayoría de los predictores retenidos resultaron estadísticamente significativos ($p < 0,05$) y sus signos concuerdan con la literatura teórica sobre deserción universitaria, lo que respalda la validez interpretativa del modelo.

Tabla 8. Resultados de la regresión logística Lasso (L1), con $C = 0,1$

Variable	Coefficiente (β)	Error estándar	Valor z	p-valor	IC 95% Inferior	IC 95% Superior
Intercepto	0,178	0,371	0,480	0,631	-0,550	0,906
Estudios máximos: Educación Secundaria	-0,190	0,134	-1,422	0,155	-0,453	0,072
Estudios máximos: Otro	0,556	0,671	0,828	0,408	-0,759	1,871
Estudios máximos: Superior - Pregrado	-0,356	0,159	-2,241	0,025	-0,667	-0,045
Estado civil: Otro	0,353	0,212	1,668	0,095	-0,062	0,768
Estado civil: Soltero	0,417	0,122	3,420	0,001	0,178	0,656
Carrera: Ciencias agropecuarias y veterinarias	-0,242	0,082	-2,937	0,003	-0,403	-0,080
Carrera: Ciencias sociales	-0,343	0,072	-4,767	<0,001	-0,485	-0,202
Carrera: Comunicación, marketing y diseño	-0,586	0,071	-8,298	<0,001	-0,725	-0,448
Carrera: Ingeniería y tecnología	1,383	0,179	7,708	<0,001	1,032	1,735
Carrera: Salud	-0,892	0,081	-11,033	<0,001	-1,051	-0,734
Puntaje de ingreso	-0,037	0,004	-8,993	<0,001	-0,045	-0,029
Edad de inscripción	0,024	0,005	4,753	<0,001	0,014	0,034

Variable	Coefficiente (β)	Error estándar	Valor z	p-valor	IC 95% Inferior	IC 95% Superior
Tiene necesidades educativas especiales	0,812	0,316	2,571	0,010	0,193	1,431
Es masculino	0,513	0,054	9,449	<0,001	0,406	0,619
Es moroso	3,469	0,140	24,834	<0,001	3,195	3,743
Es becado	-1,353	0,067	-20,127	<0,001	-1,485	-1,221
Es estudiante internacional	-0,815	0,297	-2,745	0,006	-1,396	-0,233
Promedio cantidad evaluaciones semestres	0,247	0,009	28,404	<0,001	0,230	0,264
Ingresos familia nivel	-0,099	0,022	-4,574	<0,001	-0,142	-0,057
Índice rendimiento académico	-3,330	0,044	-75,125	<0,001	-3,417	-3,243

Regresión logística Lasso con regularización L1 y $\lambda C=0,1$, ajustada con el conjunto de entrenamiento ($N = 32.188$). β = coeficiente en escala log-odds; IC 95 % = intervalo de confianza al 95 %. Las categorías de las variables categóricas se comparan con sus categorías de referencia.

En el conjunto de prueba, este modelo obtuvo un F1-macro de 0,93, similar al del modelo logístico con más variables (Tabla 7). La Tabla 9 presenta su matriz de confusión, calculada también sobre el conjunto de prueba.

Tabla 9. Matriz de confusión de la regresión logística explicativa (conjunto de prueba)

	Predicho: Clase 0	Predicho: Clase 1	Total Real
Real: Clase 0	4.579	163	4.742
Real: Clase 1	407	2.899	3.306
Total Predicho	4.986	3.062	8.048

Matriz de confusión de la regresión logística explicativa en el conjunto de prueba ($N = 8.048$). Filas = clase real; columnas = clase predicha; 0 = graduado y 1 = desertor. La diagonal contiene los aciertos y las restantes celdas, los errores.

Importancia de las variables

La Figura 5 muestra cómo varían los coeficientes del modelo Lasso entrenado a lo largo del rango de C . El coeficiente del índice de rendimiento académico permanece alejado de cero incluso con regularización intensa, mientras que los de morosidad y algunas categorías de carrera aumentan al reducirse la penalización. Esto sugiere que el índice aporta una señal predictiva estable en este modelo. El análisis de la trayectoria se complementa con la importancia por permutación de la Figura 6, que muestra cuánto disminuye el F1-macro al permutar cada predictor.

Evolución de coeficientes - Regularización Lasso (L1)




Figura 5. Trayectoria de los coeficientes para distintos valores de C . La línea horizontal discontinua marca el valor cero.

La importancia por permutación de la Figura 6 se calculó como la disminución del F1-macro al permutar los valores de cada predictor. En el conjunto de prueba, el índice de rendimiento académico produce la mayor disminución (aproximadamente 0,31), seguido por la morosidad (cerca de 0,05) y el promedio de evaluaciones (alrededor de 0,01). Las demás variables generan cambios menores. El patrón similar entre entrenamiento y prueba indica que estas variables aportan información a las predicciones de esta regresión logística.




Figura 6. *Disminución del F1-macro tras permutar cada predictor*. Los paneles corresponden a entrenamiento y prueba; una disminución mayor indica una contribución predictiva mayor en este modelo.

Discusión

Los resultados abordan la deserción desde tres perspectivas relacionadas: reconocer la situación académica, anticipar el abandono y comprender qué variables se asocian con él. En la clasificación multiclase, Gradient Boosting obtuvo el mayor F1-macro (0,7828; Tabla 5), pero la matriz de confusión muestra que identificó correctamente el 59,5 % de los estudiantes «En curso», frente al 91,9 % de graduados y al 81,6 % de desertores (Tabla 6). La superposición de algunas distribuciones en los diagramas de caja (Figura 2) ayuda a comprender esta diferencia. Por ello, el resultado global debe considerarse junto con el desempeño de cada clase: «En curso» es la categoría más difícil de reconocer, aunque representa un estado académico distinto de «Graduado».

El objetivo predictivo binario es distinto: busca anticipar el abandono a partir de la información del primer año. Gradient Boosting obtuvo un F1-macro de 0,9404, prácticamente igual al de SVM (0,9403), mientras que el ensamble *Voting (soft)* no superó a los modelos individuales (Tabla 7). El F1-macro resume el equilibrio entre precisión y *recall* para las clases graduado y desertor. En este análisis, el modelo se entrenó y evaluó con casos históricos cuyo desenlace se conoce; se propone aplicarlo a estudiantes «En curso» de cohortes futuras para estimar el riesgo de abandono y orientar acciones de acompañamiento. Así, la tarea multiclase describe los estados académicos observados, mientras que la binaria se orienta a generar una predicción para quienes continúan estudiando.

El objetivo explicativo busca identificar qué factores se asocian con la deserción. En la regresión logística reducida, los coeficientes (Tabla 8) y la importancia por permutación (Figura 6) destacan el índice de rendimiento académico y la morosidad; el promedio de evaluaciones también aporta información, aunque en menor medida. Las curvas ofrecen evidencia complementaria: en la Figura 4, el F1-macro se estabiliza cerca de 0,1 desde valores pequeños de C , con resultados de entrenamiento y prueba próximos; en la Figura 5, el coeficiente del índice académico permanece alejado de cero incluso bajo una regularización intensa. La importancia del rendimiento coincide con los enfoques de integración académica de Tinto (1975, 1993), y la de factores económicos o administrativos es compatible con modelos que contemplan condiciones individuales y contextuales (Bean, 1980; Bean y Metzner, 1985; Yorke y Longden, 2004). Como el análisis es observacional, estos hallazgos describen asociaciones y no permiten afirmar que las variables identificadas causen la deserción.

Conclusión

Con base en los resultados, Gradient Boosting permite distinguir los tres estados académicos en la tarea multiclase (F1-macro = 0,7828), aunque reconoce con menor acierto a «En curso» (59,5 %). En la tarea binaria predictiva, Gradient Boosting distingue graduados de desertores con buen desempeño a partir de variables académicas y personales disponibles al finalizar el primer año (F1-macro = 0,9404 en el conjunto de prueba), por ello, es un modelo candidato para estimar el riesgo de abandono de estudiantes «En curso» en cohortes futuras, debido a que presenta una buena precisión. Estas predicciones pueden orientar acciones de acompañamiento, pero deben apoyar el trabajo de las áreas responsables y no determinar automáticamente la trayectoria de cada estudiante. Finalmente, en la tarea binaria explicativa, la regresión logística con varias seleccionadas destaca el rendimiento académico y la morosidad como factores asociados con la deserción, bastante en línea con la literatura teórica, sin que esto quiera demostrar una relación causal.

Bibliografía

- Scikit-learn developers. (s. f.). *Permutation Importance with Multicollinear or Correlated Features* [Feature importance con permutación](#)
- Bean, J. P. (1980). Dropouts and turnover: The synthesis and test of a causal model of student attrition. *Research in Higher Education*, 12(2), 155-187.
- Bean, J. P., y Metzner, B. S. (1985). A conceptual model of nontraditional undergraduate student attrition. *Review of Educational Research*, 55(4), 485-540.
- OECD. (2019). *Education at a Glance 2019: OECD Indicators*. OECD Publishing.
- Tinto, V. (1975). Dropout from higher education: A theoretical synthesis of recent research. *Review of Educational Research*, 45(1), 89-125.
- Tinto, V. (1993). *Leaving College: Rethinking the Causes and Cures of Student Attrition* (2nd ed.). University of Chicago Press.

Yorke, M., y Longden, B. (2004). *Retention and Student Success in Higher Education*. Society for Research into Higher Education y Open University Press.